

TECH CHALLENGE

91ADT – FASE 2

dIAbetes



Otimização de Hiperparâmetros com
Algoritmo Genético e Integração com LLM



Thiago de Melo Lima – [RM370763](#)

MODELO BASE (FASE 1)



Na Fase 1 desenvolvemos um modelo de Machine Learning para diagnóstico de diabetes. Nesta fase o objetivo foi **otimizar esse modelo** utilizando Algoritmos Genéticos e integrar uma LLM para geração de explicações clínicas.

DADOS DOS PACIENTES



Características clínicas e laboratoriais



MODELO BASE (Random Forest)



Random Forest sem otimização de hiperparâmetros




AVALIAÇÃO



Métricas de desempenho

ALGORITMO UTILIZADO



RANDOM FOREST

Modelo baseado em múltiplas árvores de decisão que combinam suas previsões para obter um resultado final mais robusto e confiável.

CONFIGURAÇÃO E DESEMPENHO DO MODELO BASE

Modelo Base - Random Forest - Sem Otimização de Hiperparâmetros

`n_estimators = 80`

`max_depth = 2`

	Acurácia:	0.8052
	Precisão:	0.7000
	Recall:	0.7778
	F1-Score:	0.7368
	Especificidade:	0.8200




PONTO DE PARTIDA: Este modelo serve como baseline para comparação. Nosso objetivo na Fase 2 é encontrar combinações de hiperparâmetros que melhorem principalmente o Recall, reduzindo os falsos negativos.




Experimentos do Algoritmo Genético


- Foram realizados três experimentos modificando população e número de gerações. Durante cada geração o algoritmo avaliou os indivíduos através da função fitness.



Experimentos do Algoritmo Genético



Experimentos do Algoritmo Genético



COMPARAÇÃO DOS EXPERIMENTOS



Os experimentos apresentaram desempenhos diferentes e o **Experimento 2** foi escolhido por apresentar o maior fitness.

RESULTADOS DOS EXPERIMENTOS

		Experimento	População	Gerações	Mutação	n_estimators	max_depth	Menor Fitness	Fitness Médio	Maior Fitness	Accuracy	Precision	Recall	F1
0		Experimento 1	10	10	0.1	31	13	0.6334	0.6779	0.6986	0.8117	0.7119	0.7778	0.7434
1		Experimento 2	20	10	0.1	161	1	0.6334	0.6911	0.7150	0.7922	0.6667	0.8148	0.7333
2		Experimento 3	20	20	0.1	160	1	0.6176	0.6851	0.7150	0.7922	0.6667	0.8148	0.7333

SELEÇÃO DO MELHOR EXPERIMENTO



MELHOR EXPERIMENTO

EXPERIMENTO 2

Maior fitness e melhor recall entre os experimentos avaliados.



DETALHES DO EXPERIMENTO ESCOLHIDO

```
Experimento      Experimento 2
População        20
Gerações         10
Mutação          0.1
n_estimators      161
max_depth        1
-----
Menor Fitness    0.6334
Fitness Médio    0.6911
Maior Fitness    0.7150
-----
Accuracy         0.7922
Precision        0.6667
Recall           0.8148
F1               0.7333
-----
Name: 1, dtype: object
```

POR QUE O EXPERIMENTO 2 FOI ESCOLHIDO?



Maior Fitness: 0.7150
Superou os demais experimentos.



Maior Recall: 0.8148
Melhor capacidade de identificar pacientes diabéticos.



Melhor equilíbrio entre métricas
Desempenho consistente em Accuracy, Precision e F1-Score.



Hiperparâmetros otimizados
n_estimators = 161 e max_depth = 1 foram a combinação vencedora.



INSIGHT PRINCIPAL: O Algoritmo Genético encontrou a combinação ideal de hiperparâmetros que maximiza o desempenho do modelo, com foco em aumentar o recall e reduzir falsos negativos no diagnóstico de diabetes.

MODELO OTIMIZADO

- Novo modelo treinado com os hiperparâmetros encontrados pelo AG

dIAbetes 



Modelo Otimizado – Random Forest

Com Otimização de Hiperparâmetros
Por Algoritmo Genético



n_estimators = 161



max_depth = 1



Acurácia : 0.7922



Precisão : 0.6667



Recall : 0.8148



F1-Score : 0.7333



Especificidade : 0.7800



HIPERPARÂMETROS OTIMIZADOS

n_estimators
161

max_depth
1




Melhora no desempenho,
com aumento do **Recall**
e redução de falsos negativos!



Comparação das Métricas



- Recall: 77,8% → 81,5%
- Falsos negativos: 12 → 10
- Melhor capacidade de identificar pacientes diabéticos



Mesmo perdendo um pouco em precisão e especificidade, conseguimos aumentar justamente a métrica mais importante para esse problema, o Recall.

Matrizes de Confusão


- Redução dos falsos negativos
- Prioridade para apoio ao diagnóstico médico



No contexto médico é preferível identificar mais pacientes doentes, mesmo aumentando um pouco os falsos positivos.


ARQUITETURA DO ALGORITMO GENÉTICO

Otimização de Hiperparâmetros do Random Forest



ARQUITETURA FINAL DAS PREDIÇÕES

Do Modelo Otimizado à Geração de Relatórios com LLM




CONCLUSÃO



1. OTIMIZAÇÃO COM ALGORITMO GENÉTICO

O Algoritmo Genético conseguiu melhorar o desempenho do modelo da Fase 1, aumentando o Recall e reduzindo os falsos negativos.



Mais pacientes diabéticos corretamente identificados pelo modelo.



2. INTEGRAÇÃO COM LLM VIA OLLAMA

A integração com a LLM executada localmente permitiu transformar as predições em explicações clínicas em linguagem natural.



Resultados mais interpretáveis e alinhados à prática médica.



3. RELATÓRIOS GERADOS E PREPARAÇÃO PARA O FUTURO

Os relatórios clínicos gerados pela LLM foram armazenados para uso nas próximas fases do projeto.



BASE DE RELATÓRIOS CLÍNICOS



Base estruturada para análises futuras e possíveis aplicações de IA generativa.

SISTEMA FINAL: INTEGRAÇÃO DE TECNOLOGIAS



MACHINE LEARNING
(Modelo Preditivo)

+



ALGORITMOS GENÉTICOS
(Otimização de Hiperparâmetros)

+



INTELIGÊNCIA ARTIFICIAL
GENERATIVA (LLM)
(Explicações em
Linguagem Natural)

=



APOIO AO DIAGNÓSTICO
DE DIABETES



FERRAMENTA DE APOIO
À DECISÃO MÉDICA



IMPORTANTE: Assim como na Fase 1, a solução deve ser utilizada apenas como ferramenta de apoio, não substituindo a avaliação e o diagnóstico realizados por um profissional de saúde.

